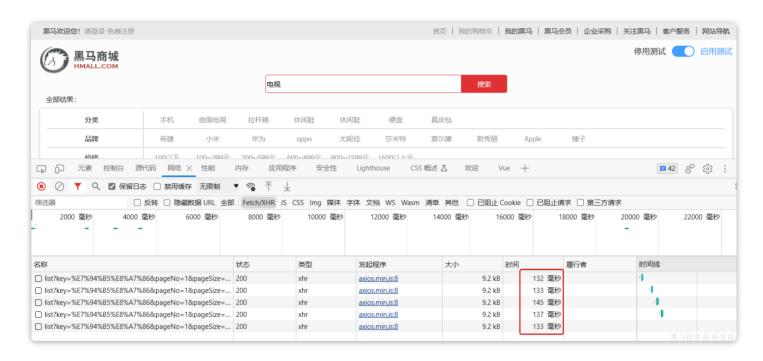
day08-Elasticsearch

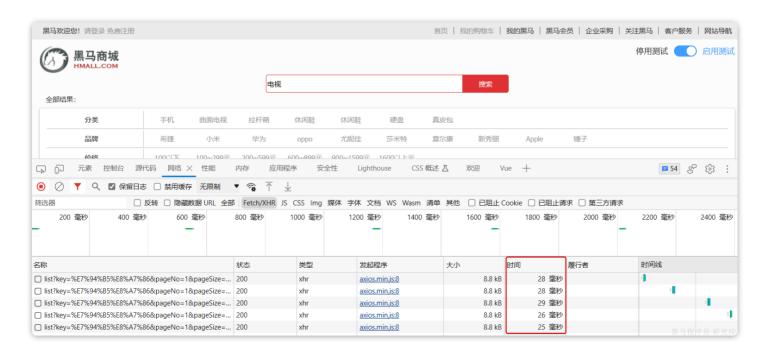
黑马商城作为一个电商项目,商品的搜索肯定是访问频率最高的页面之一。目前搜索功能是基于数据 库的模糊搜索来实现的,存在很多问题。

首先,查询效率较低。

由于数据库模糊查询不走索引,在数据量较大的时候,查询性能很差。黑马商城的商品表中仅仅有不到9万条数据,基于数据库查询时,搜索接口的表现如图:



改为基于搜索引擎后,查询表现如下:



需要注意的是,数据库模糊查询随着表数据量的增多,查询性能的下降会非常明显,而搜索引擎的性能则不会随着数据增多而下降太多。目前仅10万不到的数据量差距就如此明显,如果数据量达到百万、千万、甚至上亿级别,这个性能差距会非常夸张。

其次,功能单一

数据库的模糊搜索功能单一,匹配条件非常苛刻,必须恰好包含用户搜索的关键字。而在搜索引擎中,用户输入出现个别错字,或者用拼音搜索、同义词搜索都能正确匹配到数据。

综上,在面临海量数据的搜索,或者有一些复杂搜索需求的时候,推荐使用专门的搜索引擎来实现搜索功能。

目前全球的搜索引擎技术排名如下:

Rank					Score		
May 2021	Apr 2021	May 2020	DBMS	Database Model	May 2021	Apr 2021	May 2020
1.	1.	1.	Elasticsearch 🖽	Search engine, Multi-model 🛐	155.35	+3.18	+6.23
2.	2.	2.	Splunk	Search engine	92.11	+3.62	+4.36
3.	3.	3.	Solr	Search engine, Multi-model 👔	51.19	+0.59	-1.39
4.	4.	4.	MarkLogic 🞛	Multi-model 👔	9.52	-0.40	-1.44
5.	5.	1 8.	Algolia	Search engine	7.72	-0.15	+3.25
6.	6.	6.	Sphinx	Search engine	7.58	+0.53	+1.55
7.	7.	4 5.	Microsoft Azure Search	Search engine	6.05	-0.49	-0.07
8.	8.	4 7.	ArangoDB 🚹	Multi-model 👔	4.38	-0.39	-0.30
9.	9.	↑ 11.	Virtuoso 🚹	Multi-model 👔	3.44	+0.27	+1.09
10.	10.	10.	Amazon CloudSearch	Search engine	2.20	-0.03	-0.39
11.	11.	1 2.	Xapian	Search engine	0.88	-0.02	+0.13
12.	12.	1 3.	CrateDB 🚹	Multi-model 👔	0.77	+0.02	+0.09
13.	13.	↑ 15.	Alibaba Cloud Log Service 🚦	Search engine	0.44	-0.01	+0.17

排名第一的就是我们今天要学习的elasticsearch.

elasticsearch是一款非常强大的开源搜索引擎,支持的功能非常多,例如:



代码搜索



商品搜索



解决方案搜索



地图搜索

通过今天的学习大家要达成下列学习目标:

- 理解倒排索引原理
- 会使用IK分词器
- 理解索引库Mapping映射的属性含义
- 能创建索引库及映射
- 能实现文档的CRUD

1.初识elasticsearch

Elasticsearch的官方网站如下:

https://www.elastic.co/cn/elasticsearch/

www.elastic.co

本章我们一起来初步了解一下Elasticsearch的基本原理和一些基础概念。

1.1.认识和安装

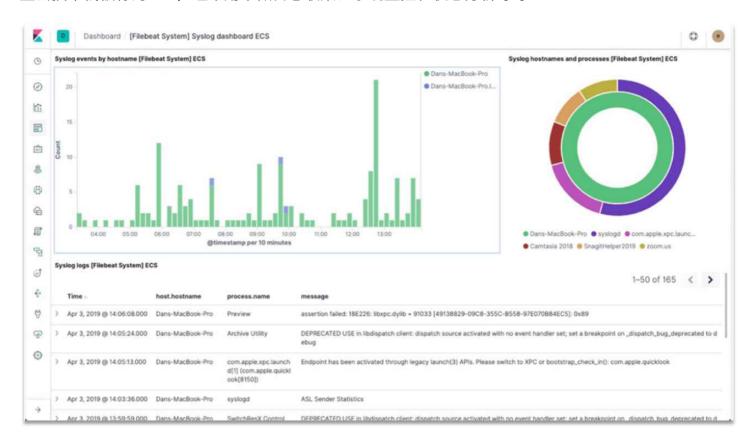
Elasticsearch是由elastic公司开发的一套搜索引擎技术,它是elastic技术栈中的一部分。完整的技术 栈包括:

• Elasticsearch: 用于数据存储、计算和搜索

• Logstash/Beats: 用于数据收集

• Kibana: 用于数据可视化

整套技术栈被称为ELK,经常用来做日志收集、系统监控和状态分析等等:



整套技术栈的核心就是用来**存储、搜索、计算**的Elasticsearch,因此我们接下来学习的核心也是Elasticsearch。

我们要安装的内容包含2部分:

• elasticsearch: 存储、搜索和运算

• kibana: 图形化展示

首先Elasticsearch不用多说,是提供核心的数据存储、搜索、分析功能的。

然后是Kibana,Elasticsearch对外提供的是Restful风格的API,任何操作都可以通过发送http请求来完成。不过http请求的方式、路径、还有请求参数的格式都有严格的规范。这些规范我们肯定记不住,因此我们要借助于Kibana这个服务。

Kibana是elastic公司提供的用于操作Elasticsearch的可视化控制台。它的功能非常强大,包括:

- 对Elasticsearch数据的搜索、展示
- 对Elasticsearch数据的统计、聚合,并形成图形化报表、图形
- 对Elasticsearch的集群状态监控
- 它还提供了一个开发控制台(DevTools),在其中对Elasticsearch的Restful的API接口提供了语法
 提示

1.1.1.安装elasticsearch

通过下面的Docker命令即可安装单机版本的elasticsearch:

```
1 docker run -d \
2 --name es \
    -e "ES_JAVA_OPTS=-Xms512m -Xmx512m" \
3
    -e "discovery.type=single-node" \
4
5
    -v es-data:/usr/share/elasticsearch/data \
     -v es-plugins:/usr/share/elasticsearch/plugins \
6
7
     --privileged \
8
     --network hm-net \
    -p 9200:9200 \
10 -p 9300:9300 \
11 elasticsearch:7.12.1
```

注意,这里我们采用的是elasticsearch的7.12.1版本,由于8以上版本的JavaAPI变化很大,在企业中应用并不广泛,企业中应用较多的还是8以下的版本。

如果拉取镜像困难,可以直接导入课前资料提供的镜像tar包:



安装完成后,访问9200端口,即可看到响应的Elasticsearch服务的基本信息:



1.1.2.安装Kibana

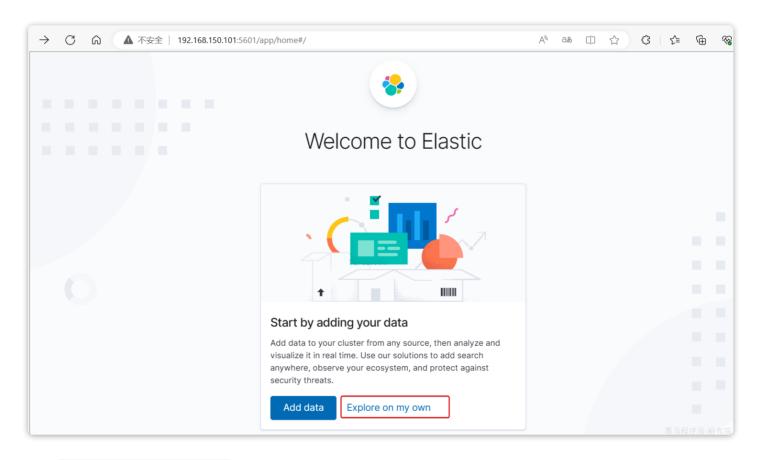
通过下面的Docker命令,即可部署Kibana:

```
1 docker run -d \
2 --name kibana \
3 -e ELASTICSEARCH_HOSTS=http://es:9200 \
4 --network=hm-net \
5 -p 5601:5601 \
6 kibana:7.12.1
```

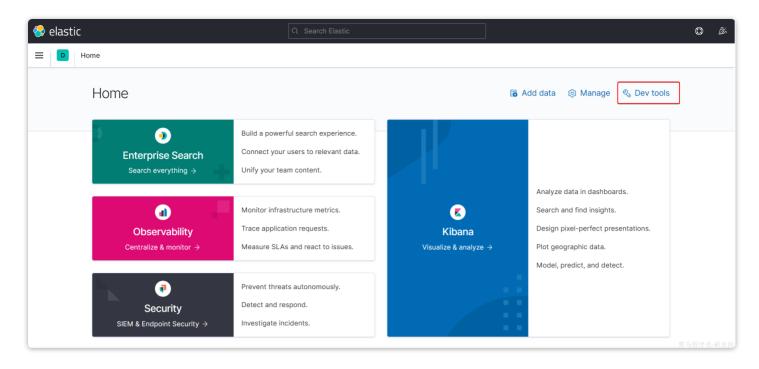
如果拉取镜像困难,可以直接导入课前资料提供的镜像tar包:



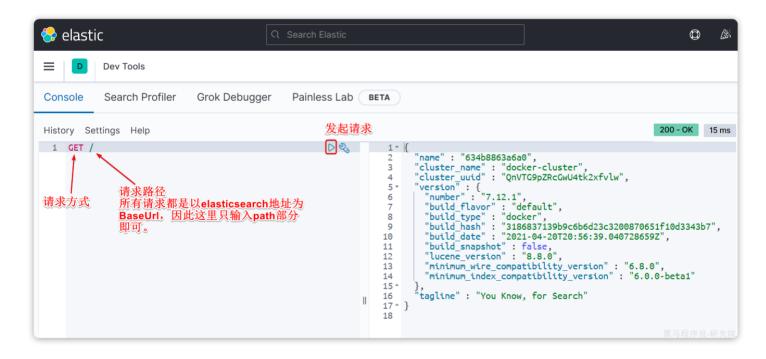
安装完成后,直接访问5601端口,即可看到控制台页面:



选择 Explore on my own 之后,进入主页面:



然后选中 Dev tools ,进入开发工具页面:



1.2.倒排索引

elasticsearch之所以有如此高性能的搜索表现,正是得益于底层的倒排索引技术。那么什么是倒排索引呢?

倒排索引的概念是基于MySQL这样的**正向**索引而言的。

1.2.1.正向索引

我们先来回顾一下正向索引。

例如有一张名为 tb_goods 的表:

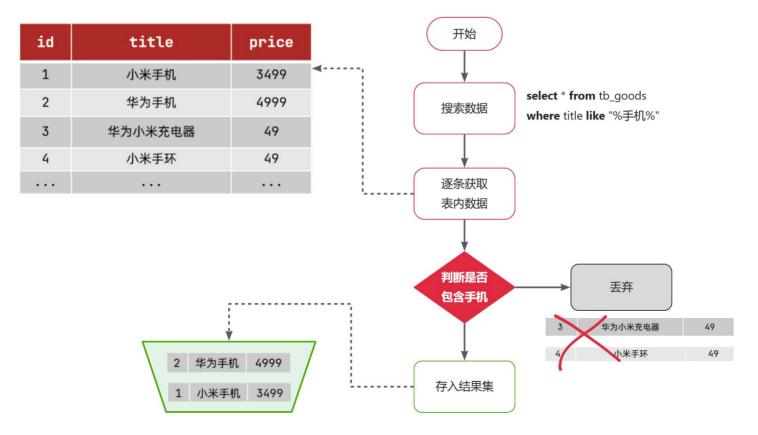
id	title	price	
1	小米手机	3499	
2	华为手机	4999	
3	华为小米充电器	49	
4	小米手环	49	

其中的 id 字段已经创建了索引,由于索引底层采用了B+树结构,因此我们根据id搜索的速度会非常快。但是其他字段例如 title ,只在叶子节点上存在。

因此要根据 title 搜索的时候只能遍历树中的每一个叶子节点,判断title数据是否符合要求。 比如用户的SQL语句为:

1 select * from tb_goods where title like '%手机%';

那搜索的大概流程如图:



说明:

- 1) 检查到搜索条件为 like '%手机%', 需要找到 title 中包含 手机 的数据
- 2)逐条遍历每行数据(每个叶子节点),比如第1次拿到 id 为1的数据
- 3)判断数据中的 title 字段值是否符合条件
- 4)如果符合则放入结果集,不符合则丢弃
- 5) 回到步骤1

综上,根据id精确匹配时,可以走索引,查询效率较高。而当搜索条件为模糊匹配时,由于索引无法 生效,导致从索引查询退化为全表扫描,效率很差。

因此,正向索引适合于根据索引字段的精确搜索,不适合基于部分词条的模糊匹配。

而倒排索引恰好解决的就是根据部分词条模糊匹配的问题。

1.2.2.倒排索引

倒排索引中有两个非常重要的概念:

- 文档(Document):用来搜索的数据,其中的每一条数据就是一个文档。例如一个网页、一个商品信息
- 词条(Term): 对文档数据或用户搜索数据,利用某种算法分词,得到的具备含义的词语就是词条。例如: 我是中国人,就可以分为: 我、是、中国人、中国、国人这样的几个词条

创建倒排索引是对正向索引的一种特殊处理和应用,流程如下:

- 将每一个文档的数据利用分词算法根据语义拆分,得到一个个词条
- 创建表,每行数据包括词条、词条所在文档id、位置等信息
- 因为词条唯一性,可以给词条创建**正向**索引

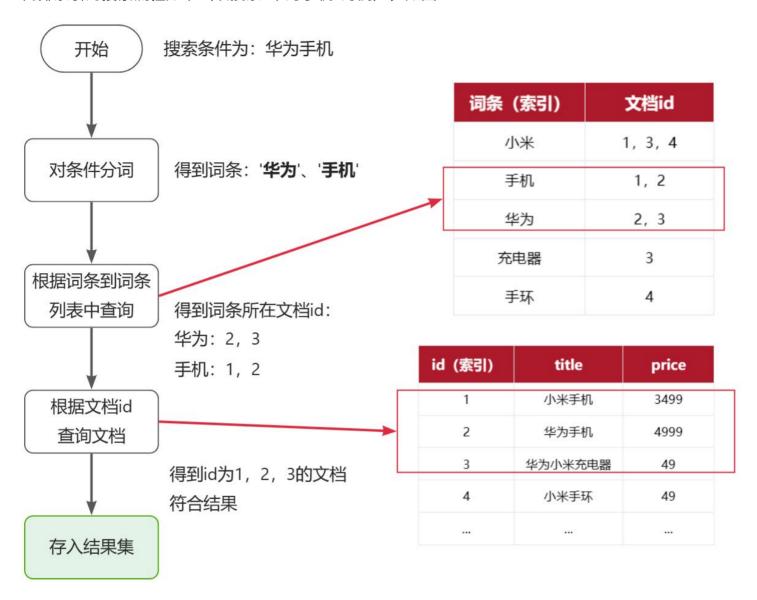
此时形成的这张以词条为索引的表,就是倒排索引表,两者对比如下:

正向索引 倒排索引

id(索引)	title	price	
1	小米手机	3499	
2	华为手机	4999	
3	华为小米充电器	49	
4	小米手环	49	
		•••	

词条(索引)	文档id
小米	1, 3, 4
手机	1, 2
华为	2, 3
充电器	3
手环	4
手环	4

倒排索引的搜索流程如下(以搜索"华为手机"为例),如图:



流程描述:

- 1) 用户输入条件"华为手机"进行搜索。
- 2) 对用户输入条件分词,得到词条: 华为、 手机。
- 3) 拿着词条在倒排索引中查找(**由于词条有索引,查询效率很高**),即可得到包含词条的文档id: 1、2、3。
- 4) 拿着文档 id 到正向索引中查找具体文档即可(由于 id 也有索引,查询效率也很高)。

虽然要先查询倒排索引,再查询倒排索引,但是无论是词条、还是文档id都建立了索引,查询速度非常快!无需全表扫描。

1.2.3.正向和倒排

那么为什么一个叫做正向索引,一个叫做倒排索引呢?

- **正向索引**是最传统的,根据id索引的方式。但根据词条查询时,必须先逐条获取每个文档,然后判断文档中是否包含所需要的词条,是**根据文档找词条的过程**。
- 而**倒排索引**则相反,是先找到用户要搜索的词条,根据词条得到保护词条的文档的id,然后根据id 获取文档。是**根据词条找文档的过程**。

是不是恰好反过来了?

那么两者方式的优缺点是什么呢?

正向索引:

- 优点:
 - 。 可以给多个字段创建索引
 - 。 根据索引字段搜索、排序速度非常快
- 缺点:
 - 根据非索引字段,或者索引字段中的部分词条查找时,只能全表扫描。

倒排索引:

- 优点:
 - 。 根据词条搜索、模糊搜索时,速度非常快
- 缺点:
 - 。 只能给词条创建索引,而不是字段
 - 。 无法根据字段做排序

1.3.基础概念

elasticsearch中有很多独有的概念,与mysql中略有差别,但也有相似之处。

1.3.1.文档和字段

elasticsearch是面向**文档(Document)**存储的,可以是数据库中的一条商品数据,一个订单信息。 文档数据会被序列化为 json 格式后存储在 elasticsearch 中:

```
1 {
2    "id": 1,
3    "title": "小米手机",
4    "price": 3499
```

id (索引)	title	price	
1	小米手机	3499	
2	华为手机	4999	
3	华为小米充电器	49	
4	小米手环	49	



```
5 }
 6 {
 7
       "id": 2,
       "title": "华为手机",
 8
       "price": 4999
 9
10 }
11 {
       "id": 3,
12
       "title": "华为小米充电器",
13
14
       "price": 49
15 }
16 {
       "id": 4,
17
18
       "title": "小米手环",
       "price": 299
19
20 }
21
```

因此,原本数据库中的一行数据就是ES中的一个JSON文档;而数据库中每行数据都包含很多列,这些列就转换为JSON文档中的**字段(Field)**。

1.3.2.索引和映射

随着业务发展,需要在es中存储的文档也会越来越多,比如有商品的文档、用户的文档、订单文档等等:

```
{
   {
                                                                                                       "id": 1,
"title": "小米手机",
        "id": 103,
        "name": "麻子",
                                                                                                       "price": 3499
                                                 "id": 10,
        "age": 18
                                                  "userId": 101,
"goodsId": 1,
                                                                                                  }
    }
                                                  "totalFee": 294
                                                                            {
                                                                                "id": 3,
"title": "三星手机",
               {
                   "id": 11,
                                                                                "price": 3999
                   "userId": 102,
                   "goodsId": 2,
"totalFee": 328
                                                                                              "id": 101,
{
                                                   {
    "id": 102,
                                                       "id": 2,
                                                                                              "name": "张三",
                                                                                              "age": 21
                                                       "title": "华为手机",
    "name": "李四",
    "age": 24
                                                        "price": 4999
}
                                                   }
```

所有文档都散乱存放显然非常混乱,也不方便管理。

因此,我们要将类型相同的文档集中在一起管理,称为**索引(Index)**。例如:

```
1 {
2
      "id": 1,
      "title": "小米
  手机",
     "price": 3499
5 }
6
7 {
      "id": 2,
      "title": "华为
  手机",
10 "price": 4999
11 }
12
13 {
    "id": 3,
14
      "title": "三星
15
  手机",
    "price": 3999
16
17 }
```

```
"id": 101,
3
     "name": "张
   Ξ",
     "age": 21
 5 }
 6
7 {
      "id": 102,
      "name": "李
   四",
10
     "age": 24
11 }
12
13 {
     "id": 103,
14
     "name": "麻
1.5
  子",
16 "age": 18
17 }
```

```
2
       "id": 10,
3
       "userId": 101,
4
       "goodsId": 1,
       "totalFee":
5
   294
6 }
7
8 {
9
       "id": 11,
       "userId": 102,
10
       "goodsId": 2,
11
      "totalFee":
12
   328
13 }
14
```

- 所有用户文档,就可以组织在一起,称为用户的索引;
- 所有商品的文档,可以组织在一起,称为商品的索引;
- 所有订单的文档,可以组织在一起,称为订单的索引;

因此,我们可以把索引当做是数据库中的表。

数据库的表会有约束信息,用来定义表的结构、字段的名称、类型等信息。因此,索引库中就有**映射** (mapping),是索引中文档的字段约束信息,类似表的结构约束。

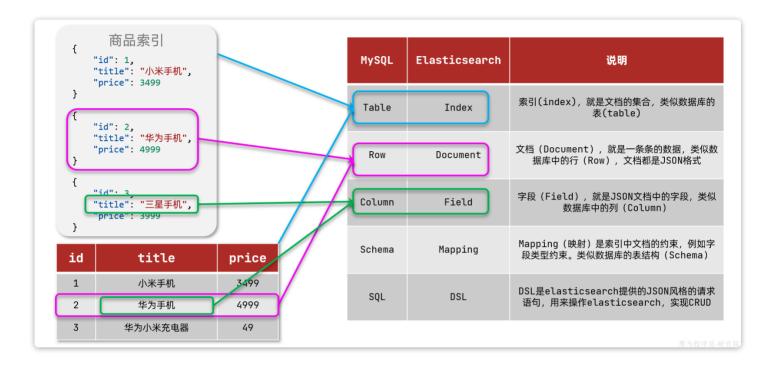
1.3.3.mysql与elasticsearch

我们统一的把mysql与elasticsearch的概念做一下对比:

MySQ L	Elasticsearc h	说明
Table	Index	索引(index),就是文档的集合,类似数据库的表(table)
Row	Document	文档(Document),就是一条条的数据,类似数据库中的行(Row),文档都是 JSON格式
Colum n	Field	字段(Field),就是JSON文档中的字段,类似数据库中的列(Column)

Schem	Mapping	Mapping(映射)是索引中文档的约束,例如字段类型约束。类似数据库的表结构(Schema)
SQL	DSL	DSL是elasticsearch提供的JSON风格的请求语句,用来操作elasticsearch,实现 CRUD

如图:



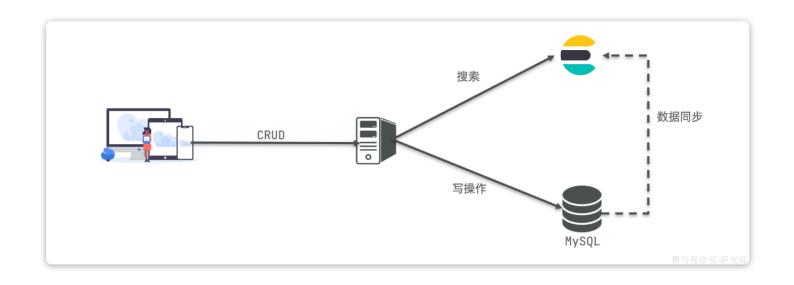
那是不是说,我们学习了elasticsearch就不再需要mysql了呢? 并不是如此,两者各自有自己的擅长之处:

• Mysql: 擅长事务类型操作,可以确保数据的安全和一致性

Elasticsearch: 擅长海量数据的搜索、分析、计算

因此在企业中,往往是两者结合使用:

- 对安全性要求较高的写操作,使用mysql实现
- 对查询性能要求较高的搜索需求,使用elasticsearch实现
- 两者再基于某种方式,实现数据的同步,保证一致性



1.4.IK分词器

Elasticsearch的关键就是倒排索引,而倒排索引依赖于对文档内容的分词,而分词则需要高效、精准的分词算法,IK分词器就是这样一个中文分词算法。

1.4.1.安装IK分词器

方案一: 在线安装

运行一个命令即可:

1 docker exec -it es ./bin/elasticsearch-plugin install
https://github.com/medcl/elasticsearch-analysisik/releases/download/v7.12.1/elasticsearch-analysis-ik-7.12.1.zip

然后重启es容器:

1 docker restart es

方案二: 离线安装

如果网速较差,也可以选择离线安装。

首先,查看之前安装的Elasticsearch容器的plugins数据卷目录:

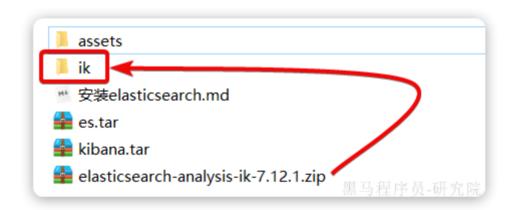
1 docker volume inspect es-plugins

结果如下:

```
1 [
      {
 2
 3
           "CreatedAt": "2024-11-06T10:06:34+08:00",
           "Driver": "local",
 5
           "Labels": null,
           "Mountpoint": "/var/lib/docker/volumes/es-plugins/_data",
 6
           "Name": "es-plugins",
 7
           "Options": null,
           "Scope": "local"
10
11 ]
```

可以看到elasticsearch的插件挂载到了 /var/lib/docker/volumes/es-plugins/_data 这个目录。我们需要把IK分词器上传至这个目录。

找到课前资料提供的ik分词器插件,课前资料提供了 7.12.1 版本的ik分词器压缩文件,你需要对其解压:



然后上传至虚拟机的 /var/lib/docker/volumes/es-plugins/_data 这个目录:



最后,重启es容器:

1.4.2.使用IK分词器

IK分词器包含两种模式:

• ik_smart: 智能语义切分

• ik_max_word: 最细粒度切分

我们在Kibana的DevTools上来测试分词器,首先测试Elasticsearch官方提供的标准分词器:

```
1 POST /_analyze
2 {
3  "analyzer": "standard",
4  "text": "黑马程序员学习java太棒了"
5 }
```

结果如下:

```
1 {
2 "tokens" : [
3
     {
        "token" : "黑",
4
5
        "start_offset" : 0,
        "end_offset" : 1,
         "type" : "<IDEOGRAPHIC>",
7
        "position" : 0
8
9
      },
10
         "token": "马",
11
         "start_offset" : 1,
12
13
         "end_offset" : 2,
14
         "type": "<IDEOGRAPHIC>",
15
        "position" : 1
16
      },
17
         "token": "程",
18
         "start_offset" : 2,
19
20
         "end_offset" : 3,
         "type" : "<IDEOGRAPHIC>",
21
```

```
"position" : 2
22
       },
23
24
       {
         "token": "序",
25
         "start_offset" : 3,
26
         "end_offset" : 4,
27
28
         "type" : "<IDEOGRAPHIC>",
29
         "position" : 3
30
       },
31
       {
         "token": "员",
32
         "start_offset" : 4,
33
         "end_offset" : 5,
34
         "type" : "<IDEOGRAPHIC>",
35
        "position" : 4
36
37
       },
       {
38
        "token": "学",
39
40
         "start_offset" : 5,
         "end_offset" : 6,
41
         "type" : "<IDEOGRAPHIC>",
42
43
        "position" : 5
44
       },
45
       {
         "token": "习",
46
47
         "start_offset" : 6,
         "end_offset" : 7,
48
         "type" : "<IDEOGRAPHIC>",
49
50
        "position" : 6
51
       },
52
         "token" : "java",
53
         "start_offset" : 7,
54
55
         "end_offset" : 11,
         "type" : "<ALPHANUM>",
56
         "position" : 7
57
58
       },
       {
59
         "token": "太",
60
         "start_offset" : 11,
61
         "end_offset" : 12,
62
         "type" : "<IDEOGRAPHIC>",
63
         "position" : 8
64
65
       },
66
       {
         "token": "棒",
67
         "start_offset" : 12,
68
```

```
"end_offset" : 13,
69
         "type" : "<IDEOGRAPHIC>",
70
71
        "position" : 9
72
       },
73
         "token": "了",
74
75
         "start_offset" : 13,
         "end_offset" : 14,
76
        "type" : "<IDEOGRAPHIC>",
77
       "position" : 10
78
79
      }
80
81 }
82
```

可以看到,标准分词器智能1字1词条,无法正确对中文做分词。 我们再测试IK分词器:

```
1 POST /_analyze
2 {
3  "analyzer": "ik_smart",
4  "text": "黑马程序员学习java太棒了"
5 }
```

执行结果如下:

```
1 {
2
   "tokens" : [
3
        "token": "黑马",
4
        "start_offset" : 0,
5
6
        "end_offset" : 2,
       "type": "CN_WORD",
7
       "position" : 0
8
9
      },
10
     {
        "token": "程序员",
11
        "start_offset" : 2,
12
        "end_offset" : 5,
13
        "type": "CN_WORD",
14
        "position" : 1
15
```

```
16
      },
      {
17
        "token" : "学习",
18
        "start_offset" : 5,
19
        "end_offset" : 7,
20
        "type" : "CN_WORD",
21
22
        "position" : 2
23
      },
24
       "token" : "java",
25
       "start_offset" : 7,
26
       "end_offset" : 11,
27
       "type" : "ENGLISH",
28
29
       "position" : 3
30
      },
31
     {
       "token": "太棒了",
32
33
       "start_offset" : 11,
34
       "end_offset" : 14,
       "type": "CN_WORD",
35
       "position" : 4
36
     }
37
38
    1
39 }
40
```

1.4.3.拓展词典

随着互联网的发展,"造词运动"也越发的频繁。出现了很多新的词语,在原有的词汇列表中并不存在。比如:"泰裤辣","传智播客"等。

IK分词器无法对这些词汇分词,测试一下:

```
1 POST /_analyze
2 {
3  "analyzer": "ik_max_word",
4  "text": "传智播客开设大学,真的泰裤辣!"
5 }
```

结果:

```
1 {
```

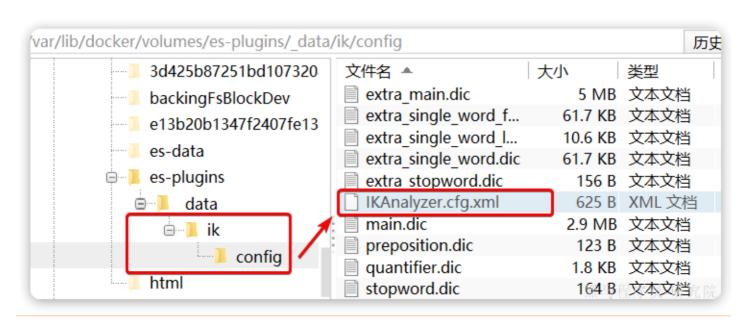
```
"tokens" : [
3
      {
         "token" : "传",
 4
5
         "start_offset" : 0,
         "end_offset" : 1,
6
         "type" : "CN_CHAR",
7
8
        "position" : 0
9
       },
10
       {
         "token": "智",
11
        "start_offset" : 1,
12
         "end_offset" : 2,
13
        "type": "CN_CHAR",
14
15
       "position" : 1
16
       },
17
       {
         "token": "播",
18
         "start_offset" : 2,
19
20
         "end_offset" : 3,
        "type": "CN_CHAR",
21
        "position" : 2
22
23
       },
      {
24
         "token": "客",
25
         "start_offset" : 3,
26
27
         "end_offset" : 4,
         "type": "CN_CHAR",
28
        "position" : 3
29
30
       },
31
       "token" : "开设",
32
        "start_offset" : 4,
33
         "end_offset" : 6,
34
35
         "type" : "CN_WORD",
        "position" : 4
36
37
       },
38
       {
         "token": "大学",
39
         "start_offset" : 6,
40
         "end_offset" : 8,
41
         "type": "CN_WORD",
42
         "position" : 5
43
44
       },
45
       {
         "token": "真的",
46
         "start_offset" : 9,
47
         "end_offset" : 11,
48
```

```
49
          "type": "CN_WORD",
          "position" : 6
50
51
       },
       {
52
         "token": "泰",
53
          "start_offset" : 11,
54
          "end_offset" : 12,
55
          "type": "CN_CHAR",
56
          "position": 7
57
58
       },
59
          "token": "裤",
60
         "start_offset" : 12,
61
62
          "end_offset" : 13,
          "type": "CN_CHAR",
63
          "position": 8
64
65
       },
66
       {
67
          "token": "辣",
         "start_offset" : 13,
68
          "end_offset" : 14,
69
         "type" : "CN_CHAR",
70
          "position": 9
71
72
       }
73
74 }
75
```

可以看到, 传智播客 和 泰裤辣 都无法正确分词。

所以要想正确分词,IK分词器的词库也需要不断的更新,IK分词器提供了扩展词汇的功能。

1) 打开IK分词器config目录:



注意,如果采用在线安装的通过,默认是没有config目录的,需要把课前资料提供的ik下的config上传至对应目录。

2) 在IKAnalyzer.cfg.xml配置文件内容添加:

3) 在IK分词器的config目录新建一个 ext.dic ,可以参考config目录下复制一个配置文件进行修改

```
1 传智播客
2 泰裤辣
```

4) 重启elasticsearch

```
1 docker restart es
2
3 # 查看 日志
4 docker logs -f elasticsearch
```

再次测试,可以发现 传智播客 和 泰裤辣 都正确分词了:

```
1 {
2 "tokens":[
3 {
4 "token": "传智播客",
5 "start_offset": 0,
6 "end_offset": 4,
7 "type": "CN_WORD",
```

```
"position" : 0
8
9
       },
10
       {
         "token": "开设",
11
         "start_offset" : 4,
12
         "end_offset" : 6,
13
14
         "type" : "CN_WORD",
         "position" : 1
15
16
       },
17
         "token" : "大学",
18
         "start_offset" : 6,
19
        "end_offset" : 8,
20
         "type": "CN_WORD",
21
        "position" : 2
22
23
       },
      {
24
        "token": "真的",
25
26
         "start_offset" : 9,
         "end_offset" : 11,
27
         "type": "CN_WORD",
28
        "position" : 3
29
30
       },
31
         "token": "泰裤辣",
32
33
        "start_offset" : 11,
       "end_offset" : 14,
34
        "type": "CN_WORD",
35
       "position" : 4
36
     }
37
38 ]
39 }
```

1.4.4.总结

分词器的作用是什么?

- 创建倒排索引时,对文档分词
- 用户搜索时,对输入的内容分词

IK分词器有几种模式?

• ik_smart: 智能切分,粗粒度

• ik_max_word: 最细切分,细粒度

IK分词器如何拓展词条? 如何停用词条?

- 利用config目录的 IkAnalyzer.cfg.xml 文件添加拓展词典和停用词典
- 在词典中添加拓展词条或者停用词条

2.索引库操作

Index就类似数据库表,Mapping映射就类似表的结构。我们要向es中存储数据,必须先创建Index和 Mapping

2.1.Mapping映射属性

Mapping是对索引库中文档的约束,常见的Mapping属性包括:

• type: 字段数据类型,常见的简单类型有:

。字符串: text (可分词的文本)、 keyword (精确值,例如:品牌、国家、ip地址)

。 数值: long 、 integer 、 short 、 byte 、 double 、 float 、

∘ 布尔: boolean

○ 日期: date

• 对象: object

• index:是否创建索引,默认为 true

• analyzer: 使用哪种分词器

• properties : 该字段的子字段

例如下面的json文档:

```
1 {
       "age": 21,
       "weight": 52.1,
       "isMarried": false,
 4
 5
       "info": "黑马程序员Java讲师",
       "email": "zy@itcast.cn",
 6
 7
       "score": [99.1, 99.5, 98.9],
 8
       "name": {
           "firstName": "云",
 9
           "lastName": "赵"
10
```

```
11 }
12 }
```

对应的每个字段映射(Mapping):

字	字段名		类型说明	是否 参与搜索	是否 参与分词	分词器
a	age		整数	$\overline{\checkmark}$		
we	ight	float	浮点数	$\overline{m{arphi}}$		
isMa	rried	boolean	布尔	✓		
ir	info		字符串,但 需要分词	⊘	⊘	IK
en	email		字符串,但 是不分词	0	0	
SC	score		只看数组中 元素类型	⊘	0	
namo	firstName	keyword	字符串,但 是不分词	⊘	0	
name	lastName	keyword	字符串,但 是不分词	⊘	0	

2.2.索引库的CRUD

由于Elasticsearch采用的是Restful风格的API,因此其请求方式和路径相对都比较规范,而且请求参数也都采用JSON风格。

我们直接基于Kibana的DevTools来编写请求做测试,由于有语法提示,会非常方便。

2.2.1.创建索引库和映射

基本语法:

• 请求方式: PUT

• 请求路径: /索引库名 ,可以自定义

• 请求参数: mapping 映射

格式:

```
1 PUT /索引库名称
2 {
3
   "mappings": {
4
      "properties": {
       "字段名":{
5
         "type": "text",
6
         "analyzer": "ik_smart"
7
8
        },
9
        "字段名2":{
        "type": "keyword",
10
        "index": "false"
11
12
       },
       "字段名3":{
13
14
        "properties": {
          "子字段": {
15
            "type": "keyword"
16
           }
17
       }
18
19
       },
       // ...略
20
21
     }
22 }
23 }
```

示例:

```
1 # PUT /heima
2 {
     "mappings": {
3
      "properties": {
        "info":{
5
          "type": "text",
6
          "analyzer": "ik_smart"
7
8
         },
         "email":{
9
          "type": "keyword",
10
          "index": "false"
11
```

```
12
      },
       "name":{
13
14
        "properties": {
           "firstName": {
15
            "type": "keyword"
16
17
18
         }
19
     }
20
21 }
22 }
```

2.2.2.查询索引库

基本语法:

• 请求方式: GET

• 请求路径:/索引库名

• 请求参数:无

格式:

```
1 GET /索引库名
```

示例:

```
1 GET /heima
```

2.2.3.修改索引库

倒排索引结构虽然不复杂,但是一旦数据结构改变(比如改变了分词器),就需要重新创建倒排索引,这简直是灾难。因此索引库**一旦创建,无法修改mapping**。

虽然无法修改mapping中已有的字段,但是却允许添加新的字段到mapping中,因为不会对倒排索引产生影响。因此修改索引库能做的就是向索引库中添加新字段,或者更新索引库的基础属性。

语法说明:

```
1 PUT /索引库名/_mapping
2 {
3    "properties": {
4         "新字段名":{
5             "type": "integer"
6         }
7     }
8 }
```

示例:

```
1 PUT /heima/_mapping
2 {
3    "properties": {
4         "age":{
5               "type": "integer"
6         }
7     }
8 }
```

2.2.4.删除索引库

语法:

• 请求方式: DELETE

• 请求路径:/索引库名

• 请求参数:无

格式:

```
1 DELETE /索引库名
```

```
1 DELETE /heima
```

2.2.5.总结

索引库操作有哪些?

• 创建索引库: PUT /索引库名

• 查询索引库: GET /索引库名

• 删除索引库: DELETE /索引库名

• 修改索引库,添加字段: PUT /索引库名/_mapping

可以看到,对索引库的操作基本遵循的Restful的风格,因此API接口非常统一,方便记忆。

3.文档操作

有了索引库,接下来就可以向索引库中添加数据了。

Elasticsearch中的数据其实就是JSON风格的文档。操作文档自然保护增、删、改、查等几种常见操作,我们分别来学习。

3.1.新增文档

语法:

```
1 POST /索引库名/_doc/文档id

2 {

3     "字段1": "值1",

4     "字段2": "值2",

5     "字段3": {

6     "子属性1": "值3",

7     "子属性2": "值4"

8     },

9 }
```

```
1 POST /heima/_doc/1
2 {
3     "info": "黑马程序员Java讲师",
4     "email": "zy@itcast.cn",
5     "name": {
6         "firstName": "云",
7         "lastName": "赵"
8     }
9 }
```

响应:



3.2.查询文档

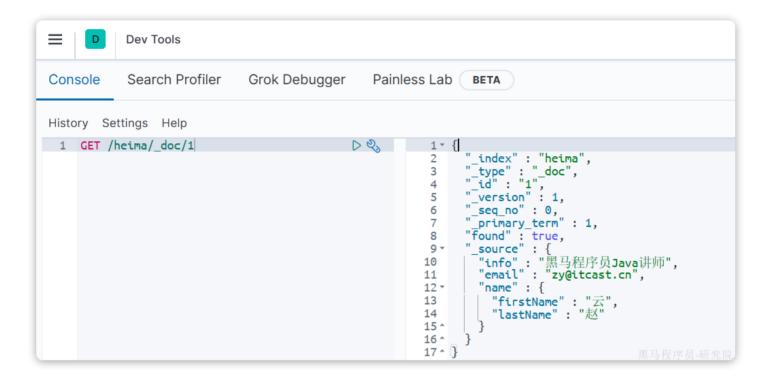
根据rest风格,新增是post,查询应该是get,不过查询一般都需要条件,这里我们把文档id带上。

语法:

```
1 GET /{索引库名称}/_doc/{id}
```

```
1 GET /heima/_doc/1
```

查看结果:



3.3.删除文档

删除使用DELETE请求,同样,需要根据id进行删除:

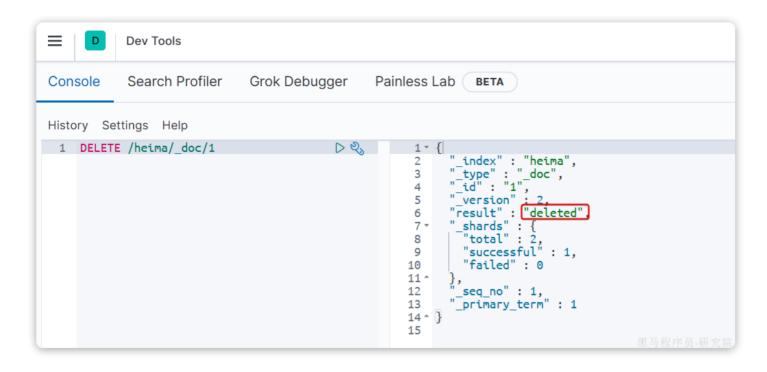
语法:

```
1 DELETE /{索引库名}/_doc/id值
```

示例:

```
1 DELETE /heima/_doc/1
```

结果:



3.4.修改文档

修改有两种方式:

• 全量修改:直接覆盖原来的文档

• 局部修改:修改文档中的部分字段

3.4.1.全量修改

全量修改是覆盖原来的文档,其本质是两步操作:

- 根据指定的id删除文档
- 新增一个相同id的文档

注意:如果根据id删除时,id不存在,第二步的新增也会执行,也就从修改变成了新增操作了。

语法:

```
1 PUT /{索引库名}/_doc/文档id
2 {
3 "字段1": "值1",
4 "字段2": "值2",
```

```
5 // ... 略
6 }
```

```
1 PUT /heima/_doc/1
2 {
3     "info": "黑马程序员高级Java讲师",
4     "email": "zy@itcast.cn",
5     "name": {
6         "firstName": "云",
7         "lastName": "赵"
8     }
9 }
```

由于 id 为 1 的文档已经被删除,所以第一次执行时,得到的反馈是 created:

```
Console
          Search Profiler Grok Debugger
                                          Painless Lab BETA
History Settings Help
                                                       1 PUT /heima/_doc/1
  2 * {
3
       "info": "黑马程序员高级Java讲师",
"email": "zy@itcast.cn",
       5 +
  8 ^
  9^}
                                                           },
"_seq_no" : 2,
"_primary_term" : 1
                                                        12
                                                        13
                                                        14 ^ }
                                                        15
```

所以如果执行第2次时,得到的反馈则是 updated:

```
Console
            Search Profiler Grok Debugger
                                                             Painless Lab BETA
History Settings Help
                                                                             1 {
2     "_index" : "heima",
3     "_type" : "_doc",
4     "_id" : "1",
5     "_version" : 2.
"     "updated"
 1 PUT /heima/_doc/1
                                                                    D 67
          "info": "黑马程序员高级Java讲师",
"email": "zy@itcast.cn",
"name": {
   3
   4
   5 +
                                                                                 | "firstName": "云",
| "lastName": "赵"
   6
   7
   8 ^
```

3.4.2.局部修改

局部修改是只修改指定id匹配的文档中的部分字段。

语法:

示例:

```
1 POST /heima/_update/1
2 {
3   "doc": {
4    "email": "ZhaoYun@itcast.cn"
5   }
6 }
```

执行结果:

```
Console
               Search Profiler
                                      Grok Debugger
                                                              Painless Lab
History Settings Help
1 POST /heima/_update/1
                                                                                         "_index" : "heima",
"_type" : "_doc",
"_id" : "1",
"_version" : 3,
"result" : "updated",
"shards" : {
  3
                                                                                  6
                                                                                            "successful" : 1,
                                                                                  9
                                                                                           "failed" : 0
                                                                                 10
                                                                                 11 *
                                                                                         },
"_seq_no" : 4,
"_primary_term" : 1
                                                                                 12
                                                                                 13
                                                                                 14 ^ }
                                                                                 15
```

3.5.批处理

批处理采用POST请求,基本语法如下:

```
1 POST _bulk
2 { "index" : { "_index" : "test", "_id" : "1" } }
3 { "field1" : "value1" }
4 { "delete" : { "_index" : "test", "_id" : "2" } }
5 { "create" : { "_index" : "test", "_id" : "3" } }
6 { "field1" : "value3" }
7 { "update" : {"_id" : "1", "_index" : "test"} }
8 { "doc" : {"field2" : "value2"} }
```

其中:

- index 代表新增操作
 - 。 _index: 指定索引库名
 - 。 _id 指定要操作的文档id
 - { "field1" : "value1" } : 则是要新增的文档内容
- delete 代表删除操作
 - _index : 指定索引库名
 - 。 _id 指定要操作的文档id
- update 代表更新操作
 - 。 _index : 指定索引库名
 - _id 指定要操作的文档id

○ { "doc" : {"field2" : "value2"} } : 要更新的文档字段

示例,批量新增:

```
1 POST /_bulk
2 {"index": {"_index":"heima", "_id": "3"}}
3 {"info": "黑马程序员C++讲师", "email": "ww@itcast.cn", "name":{"firstName": "五", "lastName":"王"}}
4 {"index": {"_index":"heima", "_id": "4"}}
5 {"info": "黑马程序员前端讲师", "email": "zhangsan@itcast.cn", "name": {"firstName": "三", "lastName":"张"}}
```

批量删除:

```
1 POST /_bulk
2 {"delete":{"_index":"heima", "_id": "3"}}
3 {"delete":{"_index":"heima", "_id": "4"}}
```

3.6.总结

文档操作有哪些?

• 创建文档: POST /{索引库名}/_doc/文档id { json文档 }

• 查询文档: GET /{索引库名}/_doc/文档id

删除文档: DELETE /{索引库名}/_doc/文档id

• 修改文档:

全量修改: PUT /{索引库名}/_doc/文档id { json文档 }

。 局部修改: POST /{索引库名}/_update/文档id { "doc": {字段}}

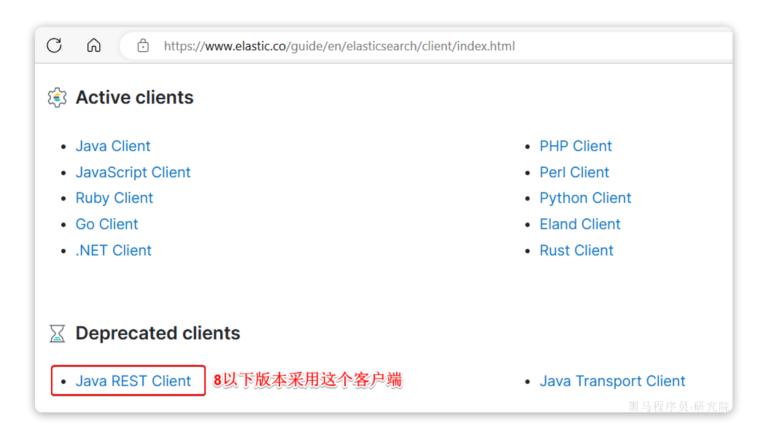
4.RestAPI

ES官方提供了各种不同语言的客户端,用来操作ES。这些客户端的本质就是组装DSL语句,通过http 请求发送给ES。

官方文档地址:

https://www.elastic.co/guide/en/elasticsearch/client/index.html

由于ES目前最新版本是8.8,提供了全新版本的客户端,老版本的客户端已经被标记为过时。而我们采用的是7.12版本,因此只能使用老版本客户端:



然后选择7.12版本,HighLevelRestClient版本:



4.1.初始化RestClient

在elasticsearch提供的API中,与elasticsearch一切交互都封装在一个名为
RestHighLevelClient 的类中,必须先完成这个对象的初始化,建立与elasticsearch的连接。

分为三步:

1) 在 item-service 模块中引入 es 的 RestHighLevelClient 依赖:

2)因为SpringBoot默认的ES版本是 7.17.10 ,所以我们需要覆盖默认的ES版本:

3) 初始化RestHighLevelClient:

初始化的代码如下:

这里为了单元测试方便,我们创建一个测试类 IndexTest ,然后将初始化的代码编写在 @BeforeEach 方法中:

```
1 package com.hmall.item.es;
2
3 import org.apache.http.HttpHost;
4 import org.elasticsearch.client.RestClient;
5 import org.elasticsearch.client.RestHighLevelClient;
6 import org.junit.jupiter.api.AfterEach;
7 import org.junit.jupiter.api.BeforeEach;
8 import org.junit.jupiter.api.Test;
```

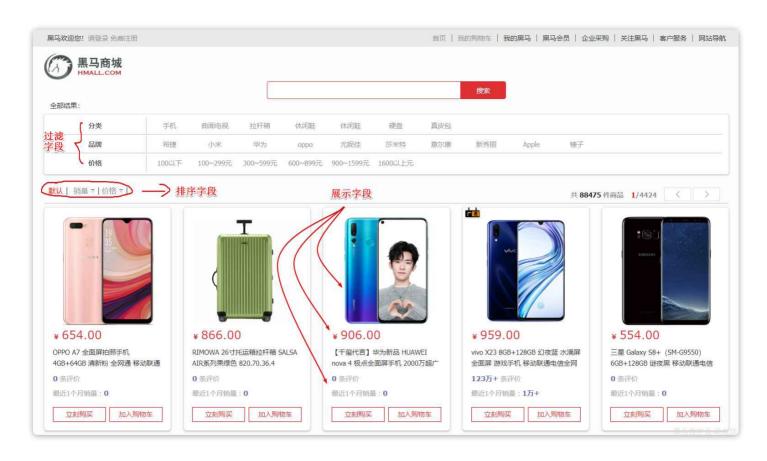
```
9
10 import java.io.IOException;
11
12 public class IndexTest {
13
       private RestHighLevelClient client;
14
15
       @BeforeEach
16
17
       void setUp() {
           this.client = new RestHighLevelClient(RestClient.builder(
18
                    HttpHost.create("http://192.168.150.101:9200")
19
           ));
20
       }
21
22
23
       @Test
       void testConnect() {
24
           System.out.println(client);
25
26
       }
27
       @AfterEach
28
       void tearDown() throws IOException {
29
           this.client.close();
30
31
       }
32 }
```

4.1.创建索引库

由于要实现对商品搜索,所以我们需要将商品添加到Elasticsearch中,不过需要根据搜索业务的需求 来设定索引库结构,而不是一股脑的把MySQL数据写入Elasticsearch.

4.1.1.Mapping映射

搜索页面的效果如图所示:



实现搜索功能需要的字段包括三大部分:

- 搜索过滤字段
 - 分类
 - 品牌
 - 价格
- 排序字段
 - 。 默认:按照更新时间降序排序
 - 销量
 - 。 价格
- 展示字段
 - 。 商品id: 用于点击后跳转
 - 图片地址
 - 。 是否是广告推广商品
 - 名称
 - 价格
 - 评价数量
 - 销量

对应的商品表结构如下,索引库无关字段已经划掉:

#	名称	数据类型	注释	长度/集合	
1	id	BIGINT	商品id	19	
2	name	VARCHAR	SKU名称	200	
3	price	INT	价格 (分)	10	
4	stock	INT	库存数量	10	
5	image	VARCHAR	商品图片	200	
6	category	VARCHAR	类目名称	200	
7	brand	VARCHAR	品牌名称	100	
8	-spec	VARCHAR	规格	200	
9	sold	INT	销量	10	
10	comment_count	INT	评论数	10	
11	isAD	TINYINT	是否是推广广告, true/false	1	
12	-status	INT	商品状态 1-正常,2-下架,3-删除	10	
13	create_time_	DATETIME	创建时间		
14	update_time	DATETIME	更新时间		
15	creater	BIGINT	创建人	19	
16	updater-	BIGINT	修改人	19 黑马程序员-研究院	

结合数据库表结构,以上字段对应的mapping映射属性如下:

字段名	字段类型	类型说明	是否 参与搜索	是否 参与分词	分词器
id	long	长整数	✓		
name	text	字符串,参与分词搜索	✓	✓	IK
price	integer	以分为单位,所以是整数	✓		
stock	integer	字符串,但需要分词	✓		
image	keyword	字符串,但是不分词			
category	keyword	字符串,但是不分词	▽	0	—
brand	keyword	字符串,但是不分词	✓	0	—
sold	integer	销量,整数	✓	0	—
commentCount	integer	评价,整数	0	0	
isAD	boolean	布尔类型	✓	0	
updateTime	Date	更新时间	✓	0	

因此, 最终我们的索引库文档结构应该是这样:

```
1 PUT /items
 2 {
 3
     "mappings": {
 4
       "properties": {
         "id": {
 5
 6
           "type": "keyword"
 7
         },
 8
         "name":{
          "type": "text",
 9
          "analyzer": "ik_max_word"
10
11
         },
         "price":{
12
          "type": "integer"
13
14
         },
15
         "stock":{
           "type": "integer"
16
         },
17
18
         "image":{
           "type": "keyword",
19
           "index": false
20
21
         },
         "category":{
22
           "type": "keyword"
23
24
         },
25
         "brand":{
          "type": "keyword"
26
27
         },
         "sold":{
28
          "type": "integer"
29
30
         },
         "commentCount":{
31
32
          "type": "integer",
33
          "index": false
34
         },
         "isAD":{
35
           "type": "boolean"
36
37
         },
         "updateTime":{
38
           "type": "date"
39
         }
40
41
       }
42
43 }
```

4.1.2.创建索引

创建索引库的API如下:



代码分为三步:

- 1) 创建Request对象。
 - 。 因为是创建索引库的操作,因此Request是 CreateIndexRequest 。
- 2)添加请求参数
 - 其实就是Json格式的Mapping映射参数。因为json字符串很长,这里是定义了静态字符串常量 MAPPING TEMPLATE,让代码看起来更加优雅。
- 3) 发送请求
 - client.indices()方法的返回值是 IndicesClient 类型,封装了所有与索引库操作有 关的方法。例如创建索引、删除索引、判断索引是否存在等

在 item-service 中的 IndexTest 测试类中,具体代码如下:

```
1 @Test
2 void testCreateIndex() throws IOException {
3 // 1.创建Request对象
```

```
CreateIndexRequest request = new CreateIndexRequest("items");
 5
        // 2.准备请求参数
        request.source(MAPPING_TEMPLATE, XContentType.JSON);
 6
 7
        // 3.发送请求
        client.indices().create(request, RequestOptions.DEFAULT);
 8
 9 }
10
11 static final String MAPPING_TEMPLATE = "{\n" +
12
                   \"mappings\": {\n" +
13
                      \"properties\": {n" + }
                        \"id\": {\n" +
14
                          "type": \"keyword"\n" +
15
                11
                        },\n" +
16
17
                        \"name\":{\n" +
                11
                          \"type\": \"text\",\n" +
18
                11
                          \"analyzer\": \"ik_max_word\"\n" +
19
                11
                        }, n'' +
20
21
                11
                        \"price\":{\n" +
22
                11
                          \"type\": \"integer\"\n" +
                11
                        }, n'' +
23
                11
24
                        \"stock\":{\n" +
25
                          \"type\": \"integer\"\n" +
26
                        }, n'' +
27
                        \"image\":{\n" +
                11
28
                          \"type\": \"keyword\",\n" +
                11
                          \": false\n" +
29
                        },\n" +
30
                11
31
                        \"category\":{\n" +
32
                11
                          \"type\": \"keyword\"\n" +
                11
                        }, n'' +
33
                        \"brand\":{\n" +
34
                11
                          "type": \"keyword"\n" +
35
                11
                        },\n" +
36
37
                11
                        \"sold\":{\n" +
38
                11
                          \"type\": \"integer\"\n" +
39
                11
                        }, n'' +
                11
                        \"commentCount\":{\n" +
40
                          \"type\": \"integer\"\n" +
                11
41
                11
42
                        }, n'' +
                        \"isAD\":{\n" +
43
                          \"type\": \"boolean\"\n" +
44
                11
                        },\n" +
45
                        \"updateTime\":{\n" +
46
                11
                          \"type\": \"date\"\n" +
47
                11
48
                        n'' +
49
                      }\n'' +
                   }\n" +
50
```

51 "}";

4.2.删除索引库

删除索引库的请求非常简单:

```
1 DELETE /hotel
```

与创建索引库相比:

- 请求方式从PUT变为DELTE
- 请求路径不变
- 无请求参数

所以代码的差异,注意体现在Request对象上。流程如下:

- 1)创建Request对象。这次是DeleteIndexRequest对象
- 2) 准备参数。这里是无参,因此省略
- 3) 发送请求。改用delete方法

在 item-service 中的 IndexTest 测试类中,编写单元测试,实现删除索引:

4.3.判断索引库是否存在

判断索引库是否存在,本质就是查询,对应的请求语句是:

因此与删除的Java代码流程是类似的,流程如下:

- 1)创建Request对象。这次是GetIndexRequest对象
- 2) 准备参数。这里是无参,直接省略
- 3)发送请求。改用exists方法

4.4.总结

JavaRestClient操作elasticsearch的流程基本类似。核心是 client.indices() 方法来获取索引库的操作对象。

索引库操作的基本步骤:

- 初始化 RestHighLevelClient
- 创建XxxIndexRequest。XXX是 Create 、 Get 、 Delete
- 准备请求参数 (Create 时需要,其它是无参,可以省略)
- 发送请求。调用 RestHighLevelClient#indices().xxx() 方法,xxx是 create 、exists 、 delete

5.RestClient操作文档

索引库准备好以后,就可以操作文档了。为了与索引库操作分离,我们再次创建一个测试类,做两件 事情:

初始化RestHighLevelClient

我们的商品数据在数据库、需要利用IHotelService去查询、所以注入这个接口

```
1 package com.hmall.item.es;
 2
 3 import com.hmall.item.service.IItemService;
 4 import org.apache.http.HttpHost;
 5 import org.elasticsearch.client.RestClient;
 6 import org.elasticsearch.client.RestHighLevelClient;
 7 import org.junit.jupiter.api.AfterEach;
 8 import org.junit.jupiter.api.BeforeEach;
 9 import org.springframework.beans.factory.annotation.Autowired;
10 import org.springframework.boot.test.context.SpringBootTest;
11
12 import java.io.IOException;
13
14 @SpringBootTest(properties = "spring.profiles.active=local")
15 public class DocumentTest {
16
       private RestHighLevelClient client;
17
       @Autowired
18
       private IItemService itemService;
19
20
       @BeforeEach
21
       void setUp() {
22
           this.client = new RestHighLevelClient(RestClient.builder(
23
24
                   HttpHost.create("http://192.168.150.101:9200")
25
           ));
       }
26
27
28
       @AfterEach
       void tearDown() throws IOException {
29
30
           this.client.close();
       }
31
32 }
```

5.1.新增文档

我们需要将数据库中的商品信息导入elasticsearch中,而不是造假数据了。

5.1.1.实体类

索引库结构与数据库结构还存在一些差异,因此我们要定义一个索引库结构对应的实体。

在 hm-service 模块的 com.hmall.item.domain.dto 包中定义一个新的DTO:

```
1 package com.hmall.item.domain.po;
2
3 import io.swagger.annotations.ApiModel;
4 import io.swagger.annotations.ApiModelProperty;
5 import lombok.Data;
6
7 import java.time.LocalDateTime;
9 @Data
10 @ApiModel(description = "索引库实体")
11 public class ItemDoc{
12
       @ApiModelProperty("商品id")
13
14
       private String id;
15
       @ApiModelProperty("商品名称")
16
       private String name;
17
18
       @ApiModelProperty("价格(分)")
19
       private Integer price;
20
21
       @ApiModelProperty("商品图片")
22
       private String image;
23
24
       @ApiModelProperty("类目名称")
25
26
       private String category;
27
       @ApiModelProperty("品牌名称")
28
29
       private String brand;
30
       @ApiModelProperty("销量")
31
       private Integer sold;
32
33
       @ApiModelProperty("评论数")
34
       private Integer commentCount;
35
36
       @ApiModelProperty("是否是推广广告,true/false")
37
       private Boolean isAD;
38
39
       @ApiModelProperty("更新时间")
40
       private LocalDateTime updateTime;
41
42 }
```

5.1.2.API语法

新增文档的请求语法如下:

```
1 POST /{索引库名}/_doc/1
2 {
3     "name": "Jack",
4     "age": 21
5 }
```

对应的JavaAPI如下:

```
void testIndexDocument() throws IOException {

// 1.创建request对象

IndexRequest request = new IndexRequest("indexName").id("1");

// 2.准备JSON文档

request.source("{\"name\": \"Jack\", \"age\": 21}", XContentType.JSON);

// 3.发送请求

client.index(request, RequestOptions.DEFAULT);
}
```

可以看到与索引库操作的API非常类似,同样是三步走:

- 1)创建Request对象,这里是 IndexRequest ,因为添加文档就是创建倒排索引的过程
- 2)准备请求参数,本例中就是Json文档
- 3) 发送请求

变化的地方在于,这里直接使用 client.xxx() 的API,不再需要 client.indices() 了。

5.1.3.完整代码

我们导入商品数据,除了参考API模板"三步走"以外,还需要做几点准备工作:

- 商品数据来自于数据库,我们需要先查询出来,得到 Item 对象
- Item 对象需要转为 ItemDoc 对象
- ItemDTO 需要序列化为 json 格式

因此,代码整体步骤如下:

• 1) 根据id查询商品数据 Item

- 2)将 Item 封装为 ItemDoc
- 3) 将 ItemDoc 序列化为JSON
- 4)创建IndexRequest,指定索引库名和id
- 5)准备请求参数,也就是JSON文档
- 6) 发送请求

在 item-service 的 DocumentTest 测试类中,编写单元测试:

```
1 @Test
2 void testAddDocument() throws IOException {
      // 1.根据id查询商品数据
      Item item = itemService.getById(100002644680L);
4
      // 2.转换为文档类型
5
      ItemDoc itemDoc = BeanUtil.copyProperties(item, ItemDoc.class);
6
      // 3.将ItemDTO转ison
7
8
       String doc = JSONUtil.toJsonStr(itemDoc);
9
      // 1.准备Request对象
10
       IndexRequest request = new IndexRequest("items").id(itemDoc.getId());
11
       // 2.准备Json文档
12
       request.source(doc, XContentType.JSON);
13
      // 3.发送请求
14
      client.index(request, RequestOptions.DEFAULT);
15
16 }
```

5.2.查询文档

我们以根据id查询文档为例

5.2.1.语法说明

查询的请求语句如下:

```
1 GET /{索引库名}/_doc/{id}
```

与之前的流程类似,代码大概分2步:

- 创建Request对象
- 准备请求参数,这里是无参,直接省略
- 发送请求

不过查询的目的是得到结果,解析为ItemDTO,还要再加一步对结果的解析。示例代码如下:

```
@Test
                                                                          GET /indexName/ doc/1
void testGetDocumentById() throws IOException {
    // 1.创建request对象
    GetRequest request = new GetRequest("indexName", "1");
                                                                            "_index" : "users",
    // 2.发送请求,得到结果
                                                                           GetResponse response = client.get(request, RequestOptions.DEFAULT);
                                                                            _id" : "1",
                                                                             version" : 1,
   String json = response.getSourceAsString();
                                                                             seq_no" : 0,
                                                                             _primary_term" : 1,
                                                                           "found" : true,
    System.out.println(json);
                                                                             source" : {
}
                                                                              "name" : "Jack",
                                                                             "age" : 21
```

可以看到,响应结果是一个JSON,其中文档放在一个 _source 属性中,因此解析就是拿到 _source ,反序列化为Java对象即可。

其它代码与之前类似,流程如下:

- 1) 准备Request对象。这次是查询,所以是 GetRequest
- 2) 发送请求,得到结果。因为是查询,这里调用 client.get() 方法
- 3)解析结果,就是对JSON做反序列化

5.2.2.完整代码

在 item-service 的 DocumentTest 测试类中,编写单元测试:

```
10    ItemDoc itemDoc = JSONUtil.toBean(json, ItemDoc.class);
11    System.out.println("itemDoc= " + ItemDoc);
12 }
```

5.3.删除文档

删除的请求语句如下:

```
1 DELETE /hotel/_doc/{id}
```

与查询相比,仅仅是请求方式从 DELETE 变成 GET ,可以想象Java代码应该依然是2步走:

- 1) 准备Request对象,因为是删除,这次是 DeleteRequest 对象。要指定索引库名和id
- 2) 准备参数,无参,直接省略
- 3) 发送请求。因为是删除,所以是 client.delete() 方法

在 item-service 的 DocumentTest 测试类中,编写单元测试:

5.4.修改文档

修改我们讲过两种方式:

全量修改:本质是先根据id删除,再新增

• 局部修改:修改文档中的指定字段值

在RestClient的API中,全量修改与新增的API完全一致,判断依据是ID:

- 如果新增时,ID已经存在,则修改
- 如果新增时,ID不存在,则新增

这里不再赘述,我们主要关注局部修改的API即可。

5.4.1.语法说明

局部修改的请求语法如下:

```
1 POST /{索引库名}/_update/{id}
2 {
3 "doc": {
4 "字段名": "字段值",
5 "字段名": "字段值"
6 }
7 }
```

代码示例如图:

```
@Test
void testUpdateDocumentById() throws IOException {
    // 1. 创建request 对象
   UpdateRequest request = new UpdateRequest("indexName", "1");
                                                                       POST /users/_update/1
    // 2.准备参数,每2个参数为一对 key value
                                                                         索引库名、
"doc": {
                                                                                        文档id
    request.doc(
                                                                           "name": "Rose",
           "age", 18,
                                                                           "age": 18
           "name", "Rose"
                                                                                   要修改的字段
   );
    // 3. 更新文档
   client.update(request, RequestOptions.DEFAULT);
}
```

与之前类似,也是三步走:

- 1) 准备 Request 对象。这次是修改,所以是 UpdateRequest
- 2) 准备参数。也就是JSON文档,里面包含要修改的字段
- 3)更新文档。这里调用 client.update() 方法

5.4.2.完整代码

在 item-service 的 DocumentTest 测试类中,编写单元测试:

```
1 @Test
2 void testUpdateDocument() throws IOException {
       // 1.准备Request
3
       UpdateRequest request = new UpdateRequest("items", "100002644680");
       // 2.准备请求参数
5
       request.doc(
6
               "price", 58800,
7
8
               "commentCount", 1
9
       );
      // 3.发送请求
10
       client.update(request, RequestOptions.DEFAULT);
11
12 }
```

5.5.批量导入文档

在之前的案例中,我们都是操作单个文档。而数据库中的商品数据实际会达到数十万条,某些项目中可能达到数百万条。

我们如果要将这些数据导入索引库,肯定不能逐条导入,而是采用批处理方案。常见的方案有:

- 利用Logstash批量导入
 - 需要安装Logstash
 - 。 对数据的再加工能力较弱
 - 。 无需编码,但要学习编写Logstash导入配置
- 利用JavaAPI批量导入
 - 。 需要编码,但基于JavaAPI,学习成本低
 - 。 更加灵活,可以任意对数据做再加工处理后写入索引库

接下来,我们就学习下如何利用JavaAPI实现批量文档导入。

5.5.1.语法说明

批处理与前面讲的文档的CRUD步骤基本一致:

- 创建Request,但这次用的是 BulkRequest
- 准备请求参数
- 发送请求,这次要用到 client.bulk() 方法

BulkRequest 本身其实并没有请求参数,其本质就是将多个普通的CRUD请求组合在一起发送。例如:

- 批量新增文档,就是给每个文档创建一个 IndexRequest 请求,然后封装到 BulkRequest 中,一起发出。
- 批量删除,就是创建N个 DeleteRequest 请求,然后封装到 BulkRequest ,一起发出

因此 BulkRequest 中提供了 add 方法,用以添加其它CRUD的请求:

BulkRequest.java					
☐ Inherited members (Ctrl+F12) ☐ Anonymous Classes (Ctrl+I) ✓ Lambdas (Ctrl+L)					
m add(DeleteRequest): BulkRequest					
m 🚡 add(DocWriteRequest): BulkRequest					
m 🖫 add(DocWriteRequest): BulkRequest					
m 🚡 add(IndexRequest): BulkRequest					
m 🚡 add(Iterable <docwriterequest<?>>): BulkRequest</docwriterequest<?>					
m 🖆 add(UpdateRequest): BulkRequest					
m ← applyGlobalMandatoryParameters(DocWriteRequest): void 黑马程序员-研究院					

可以看到,能添加的请求有:

- IndexRequest ,也就是新增
- UpdateRequest ,也就是修改
- DeleteRequest ,也就是删除

因此Bulk中添加了多个 IndexRequest ,就是批量新增功能了。示例:

```
9 client.bulk(request, RequestOptions.DEFAULT);
10 }
```

5.5.2.完整代码

当我们要导入商品数据时,由于商品数量达到数十万,因此不可能一次性全部导入。建议采用循环遍历方式,每次导入1000条左右的数据。

item-service 的 DocumentTest 测试类中,编写单元测试:

```
1 @Test
2 void testLoadItemDocs() throws IOException {
       // 分页查询商品数据
       int pageNo = 1;
4
       int size = 1000;
5
       while (true) {
6
           Page<Item> page = itemService.lambdaQuery().eq(Item::getStatus,
7
   1).page(new Page<Item>(pageNo, size));
           // 非空校验
8
9
           List<Item> items = page.getRecords();
10
           if (CollUtils.isEmpty(items)) {
               return;
11
12
          log.info("加载第{}页数据,共{}条", pageNo, items.size());
13
           // 1.创建Request
14
           BulkRequest request = new BulkRequest("items");
15
           // 2.准备参数,添加多个新增的Request
16
           for (Item item : items) {
17
              // 2.1.转换为文档类型ItemDTO
18
               ItemDoc itemDoc = BeanUtil.copyProperties(item, ItemDoc.class);
19
               // 2.2.创建新增文档的Request对象
20
               request.add(new IndexRequest()
21
                              .id(itemDoc.getId())
22
23
                               .source(JSONUtil.toJsonStr(itemDoc),
   XContentType.JSON));
24
          }
           // 3.发送请求
25
26
           client.bulk(request, RequestOptions.DEFAULT);
27
           // 翻页
28
          pageNo++;
29
       }
30
31 }
```

5.6.小结

文档操作的基本步骤:

- 初始化 RestHighLevelClient
- 创建XxxRequest。
 - ∘ XXX是 Index 、Get 、Update 、Delete 、Bulk
- 准备参数 (Index 、 Update 、 Bulk 时需要)
- 发送请求。
 - 。 调用 RestHighLevelClient#.xxx() 方法,xxx是 index 、 get 、 update 、 delete 、 bulk
- 解析结果 (Get 时需要)

6.作业

6.1.服务拆分

搜索业务并发压力可能会比较高,目前与商品服务在一起,不方便后期优化。

需求: 创建一个新的微服务,命名为 search-service ,将搜索相关功能抽取到这个微服务中

6.2.商品查询接口

在 item-service 服务中提供一个根据id查询商品的功能,并编写对应的FeignClient

6.3.数据同步

每当商品服务对商品实现增删改时,索引库的数据也需要同步更新。

提示:可以考虑采用MQ异步通知实现。